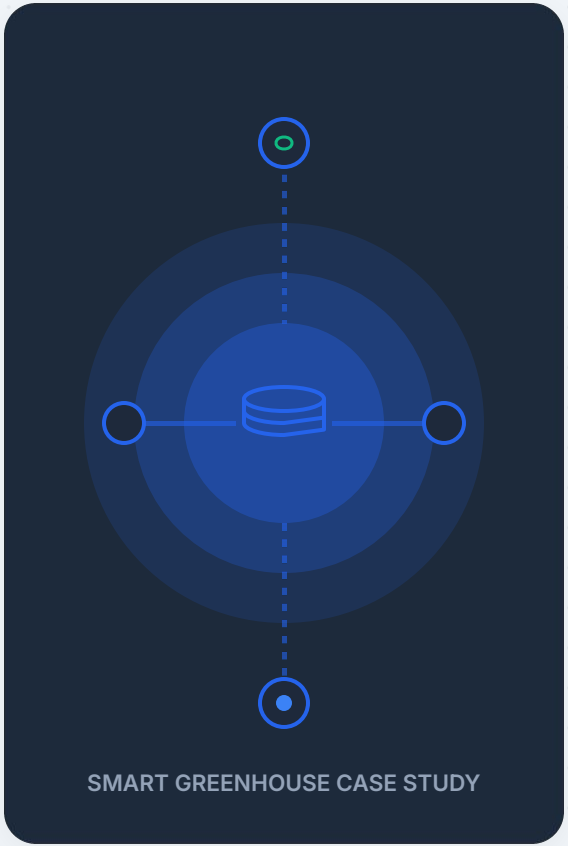
ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

DATA WAREHOUSE DESIGN APPROACHES

s.m.a.r.t. greenhouse

Group 29 - Week 5

Assoc. Prof. Dr. Võ Thị Ngọc Châu - Data Engineering (CO5173)



Thành viên thực hiện đồ án

TTH

TRẦN THU HIỀN

MSSV: 2670279

LHH

LÊ HOÀNG HIỆP

MSSV: 2470280

NHV

NGUYỄN HOÀNG VIỆT

MSSV: 2670395

NỘI DUNG TRÌNH BÀY

Từ bối cảnh lý thuyết đến case study thực tế

1. Bối cảnh lịch sử và định nghĩa
2. Trường phái 1: Bill Inmon
3. Trường phái 2: Ralph Kimball
4. Trường phái 3: Hybrid
5. Case Study: Smart Greenhouse, So sánh và Kết luận

BỐI CẢNH LỊCH SỬ

Sự Sụp Đổ Của Kiến Trúc Tự Phát

Trào lưu kết nối tự phát & những nút thắt kỹ thuật kinh điển

1. Thảm họa Mạng nhện (The Spider Web)

Kết nối point-to-point tăng theo cấp số nhân N(N-1)/2. Thực tế với 20 hệ thống nghiệp vụ đã tạo ra 190 data pipelines chằng chịt, tiêu tốn 80% tài nguyên IT chỉ cho bảo trì.

2. Khủng hoảng niềm tin (Data Credibility Crisis)

Mâu thuẫn số liệu nghiêm trọng giữa các phòng ban do lệch thời điểm trích xuất dữ liệu và sự không nhất quán trong công thức tính toán chỉ số nghiệp vụ.

3. Xung đột tài nguyên OLTP vs OLAP

Các câu lệnh truy vấn phân tích quét bảng lớn làm kiệt huệ tài nguyên CPU/RAM trên cơ sở dữ liệu tác nghiệp (OLTP), gây nghẽn hoặc sập hệ thống giao dịch hàng ngày.

MÔ HÌNH MINH HỌA

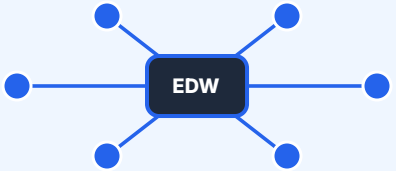
Point-to-Point Mesh vs. Centralized Architecture

Spider-Web Mesh — N(N-1)/2 Connections (190 Pipelines)



VS

Centralized Architecture — Hub & Spoke (Single EDW Hub)



[ACADEMIC REFERENCE]
W. H. Inmon (2005), 'Building the Data Warehouse' (4th Edition), John Wiley & Sons.

Định nghĩa

Bản chất của một Design Approach

Vòng đời dữ liệu và 3 câu hỏi chiến lược

ĐỊNH NGHĨA BẢN CHẤT:

Một Design Approach trong Data Engineering là khuôn khổ định nghĩa toàn bộ vòng đời của dữ liệu từ khi thu nhận dữ liệu thô, qua làm sạch, biến đổi, lưu trữ, cho đến khi trình diễn cho end-users để phục vụ ra quyết định.

STRATEGIC DECISIONS

03 CÂU HỎI CHIẾN LƯỢC QUYẾT ĐỊNH

1. Xây WH từ đâu?

Bắt đầu từ Enterprise Data Model 3NF toàn diện trước hay xuất phát nhỏ gọn từ từng Business Process cụ thể?

2. Theo quy trình nào?

Mô hình Waterfall Top-Down quy hoạch tập trung hay Mô hình Agile Iterative phát triển cuốn chiếu?

3. Phục vụ ai trước?

Ưu tiên Nguồn Sự thật Duy nhất (Enterprise SVOT) cho toàn công ty hay báo cáo phòng ban tức thời?

[Academic Reference]: M. Breslin (2004); L. Yessad & A. Labiod (IEEE, 2016).

TRƯỜNG PHÁI 1: BILL INMON (TOP-DOWN)

Triết lý Enterprise-First

"Xây móng nhà trước khi chia phòng"

- **Triết lý cốt lõi:**
  Doanh nghiệp là một thực thể thống nhất. Mọi dữ liệu phải được mô hình hóa và quy hoạch tổng thể trước khi phân phối về các phòng ban.

- **Bản chất kỹ thuật:**

Source Systems → Staging Area → EDW trung tâm

- EDW được thiết kế ở mức chuẩn hóa bậc ba (3NF - Third Normal Form) nhằm triệt tiêu hoàn toàn sự dư thừa dữ liệu và đảm bảo tính toàn vẹn tuyệt đối.

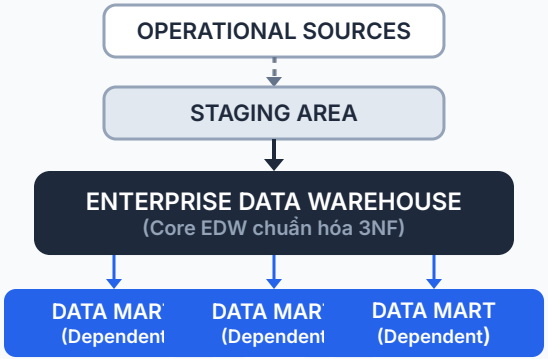
- Sau đó mới tách ra các Dependent Data Marts cho các phòng ban.

MỤC TIÊU TỐI THƯỢNG

Single Version of Truth (SVOT)

- Dữ liệu ở lõi EDW 3NF là nguồn sự thật duy nhất, tập trung và bất biến cho toàn tổ chức.
- Loại bỏ hoàn toàn mâu thuẫn số liệu giữa các bộ phận.
- Đòi hỏi chuyên môn cao về Data Modeling và thời gian đầu tư ban đầu lớn.

MÔ HÌNH KIẾN TRÚC INMON TOP-DOWN



[1] W. H. Inmon, C. Imhoff, R. Sousa (2001), 'Corporate Information Factory', John Wiley & Sons.

Mô hình Kiến trúc Corporate Information Factory (CIF)

5 Tầng kiến trúc xử lý dữ liệu theo Bill Inmon

Tầng 1: Operational Sources (ERP, CRM, Billing, Sensors) – Nguồn dữ liệu tác nghiệp thô.

Tầng 2: Data Staging Area – Vùng đệm xử lý ETL, Cleansing & Standardization.

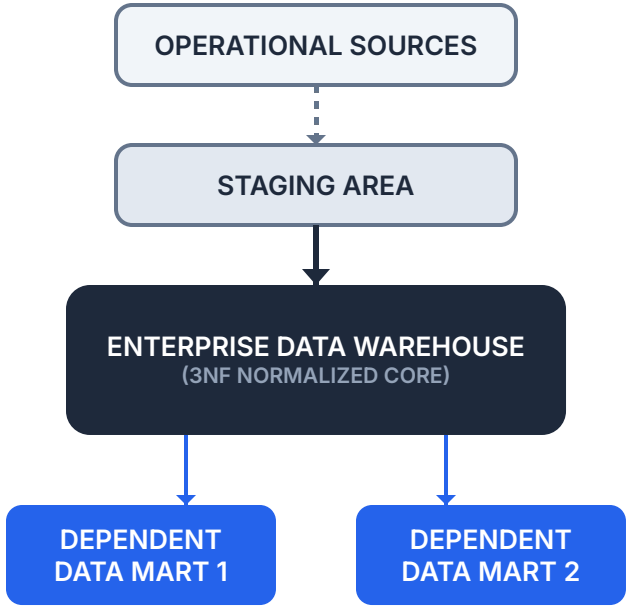
Tầng 3: ODS & Enterprise Data Warehouse (EDW) – Trái tim chuẩn hóa 3NF Normalized Core lưu trữ lịch sử nguyên tử.

Tầng 4: Data Delivery Layer – Phân phối dữ liệu ra các Dependent Data Marts.

Tầng 5: BI & Decision Support Systems – Giao diện Dashboards, OLAP, Reporting cho người dùng.

[Academic Reference]: W. H. Inmon (2005), 'Building the Data Warehouse', Wiley.

Sơ đồ Luồng Dữ liệu Inmon (CIF)



TRƯỜNG PHÁI 2 — RALPH KIMBALL

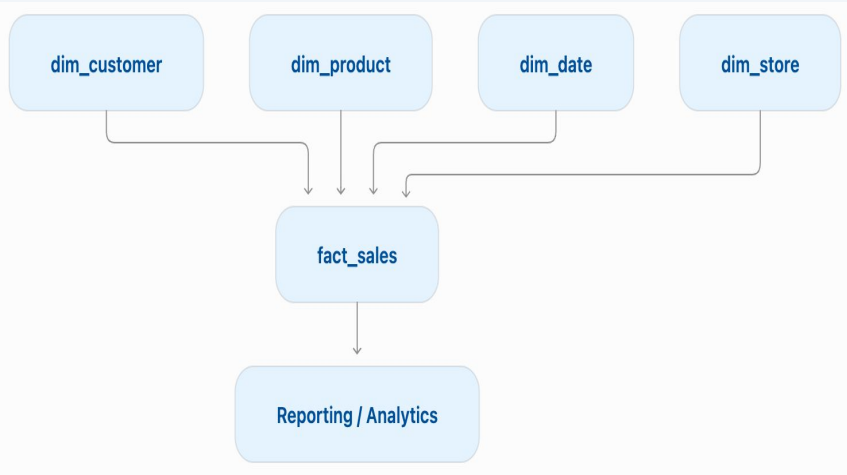
Xây Data Mart theo nhu cầu, kết nối bằng Dimension chung

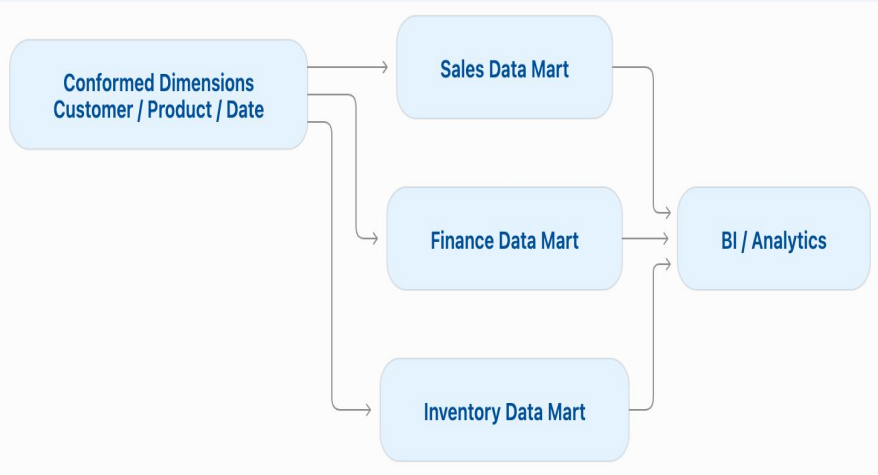


1. Bắt đầu từ business process cụ thể: Sales, Shipping, Inventory...
2. Xây các dimensional data mart phục vụ ngay nhu cầu đó
3. Mô hình dữ liệu thường dùng Star Schema (một số nguồn nhắc Snowflake Schema)
4. Các data mart kết nối bằng conformed dimensions — dimension dùng chung, định nghĩa nhất quán
5. Tập hợp các data mart tạo nên Data Warehouse Bus Architecture

"Kimball giống người phát triển từng khu dân cư — xây phần doanh nghiệp cần trước, rồi kết nối các khu bằng hạ tầng chung."

Star Schema cho từng mart, Conformed Dimensions kết nối chúng





Nếu Sales và Finance cùng phân tích theo Customer, dimension Customer phải có định nghĩa thống nhất — nếu mỗi mart tự định nghĩa khác nhau, kết quả phân tích giữa các bộ phận sẽ mâu thuẫn.

Tốc độ triển khai đổi lấy kỷ luật quản trị dimension

Điểm mạnh

- Tạo giá trị sớm theo từng mart/process
- Dimensional model dễ hiểu với business users
- Star schema thuận tiện cho reporting
- Phù hợp cách làm incremental/agile

Hạn chế

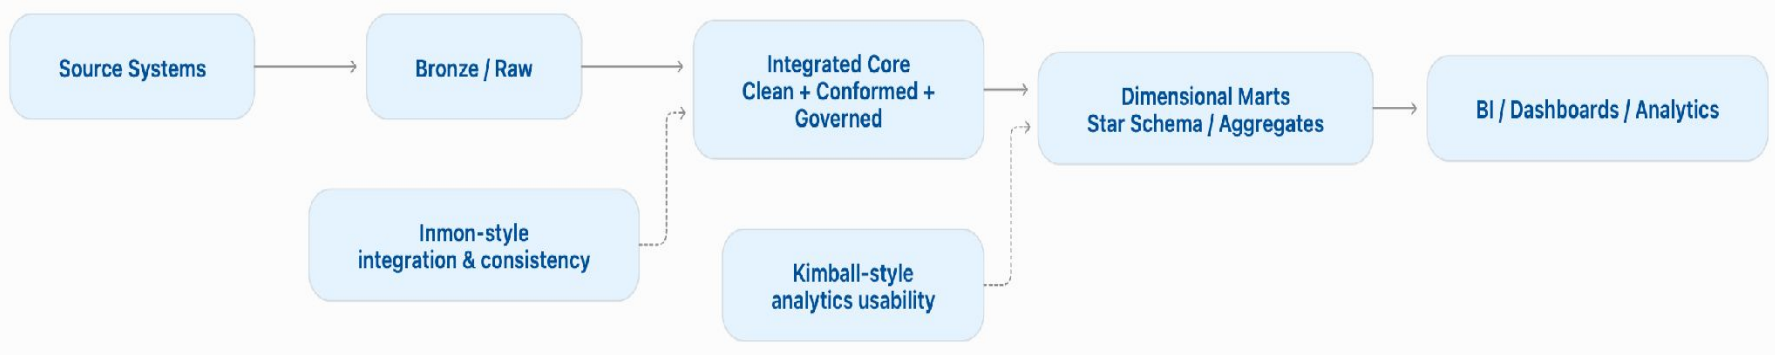
- Thiếu quản lý conformed dimensions → "data island"
- Nhiều mart → khó giữ định nghĩa nhất quán
- Grain, facts/dimensions phải thiết kế cẩn thận

Phù hợp khi

- Cần dashboard/report sớm
- Phạm vi ban đầu tương đối rõ
- Tổ chức vừa hoặc agile team
- Ưu tiên speed-to-value

TRƯỜNG PHÁI 3 - HYBRID

Trusted core (Inmon) + Serving layer dễ dùng (Kimball)



Lớp lõi (Silver) — ưu tiên tích hợp, chất lượng, tính nhất quán — gần tư duy Inmon.

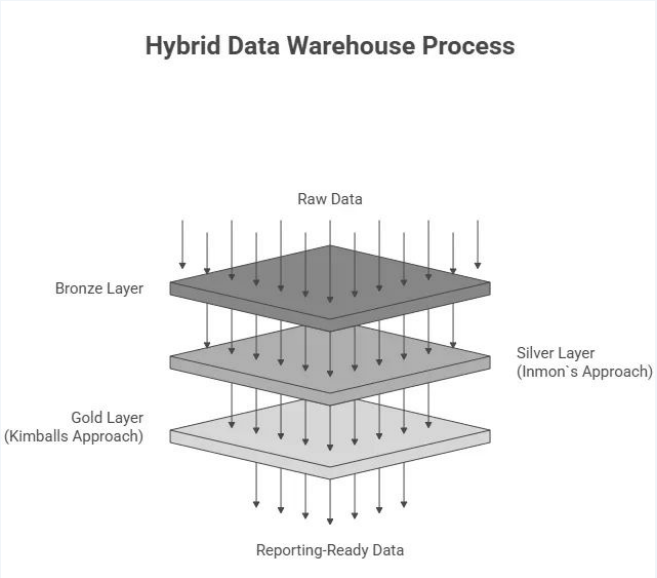
Lớp phục vụ (Gold) — Star Schema, aggregate, dễ truy vấn — gần tư duy Kimball.

Vì sao các nền tảng hiện đại làm ranh giới mờ đi?

- Ở kiến trúc cổ điển, lựa chọn thường được mô tả khá rõ:
  - **Inmon:** normalized EDW trước → data mart sau.
  - **Kimball:** dimensional marts trước → liên kết bằng conformed dimensions.

- Nhưng các data warehouse / OLAP engine hiện đại cho phép đồng thời:
  - giữ **raw + cleaned + integrated data** trong cùng một platform;
  - dùng cả **normalized, star schema và denormalized wide table** tùy workload;
  - tạo **materialized / dynamic / aggregate tables** cho các hot query;
  - tách **storage, transformation compute và BI compute**;
  - truy vấn cả dữ liệu nội bộ lẫn data lake / external systems.

→ Do đó, Inmon và Kimball ngày nay phù hợp hơn khi xem như **design philosophies** thay vì hai blueprint loại trừ lẫn nhau.

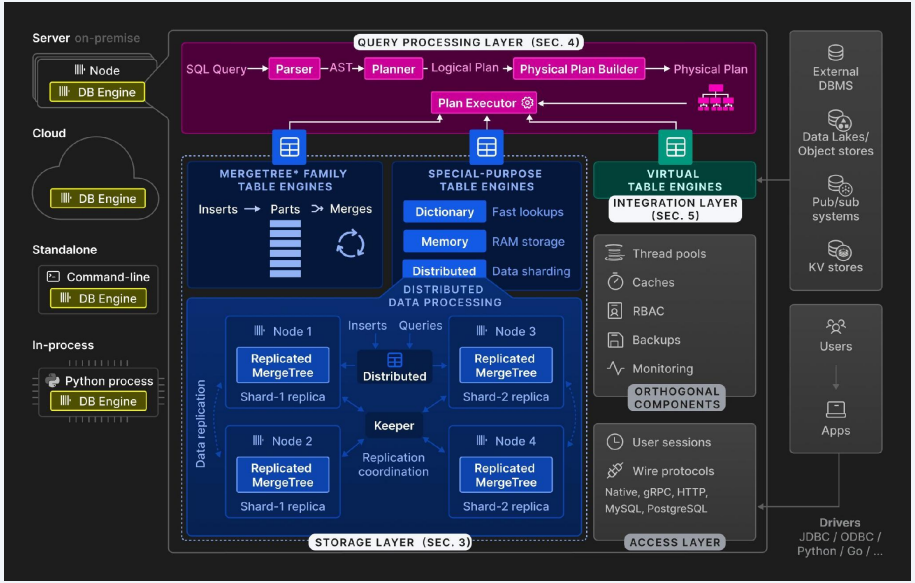


Vì sao các nền tảng hiện đại làm ranh giới mờ đi?

CLICKHOUSE

- 3 lớp: Storage (MergeTree) · Query processing · Integration
- Bronze → Silver → Gold trong cùng platform
- Normalized joins và denormalized wide table cùng tồn tại
- Materialized Views phục vụ dashboard latency thấp

"Giữ dữ liệu chuẩn hóa khi cần governance, denormalize/materialize khi cần latency thấp."



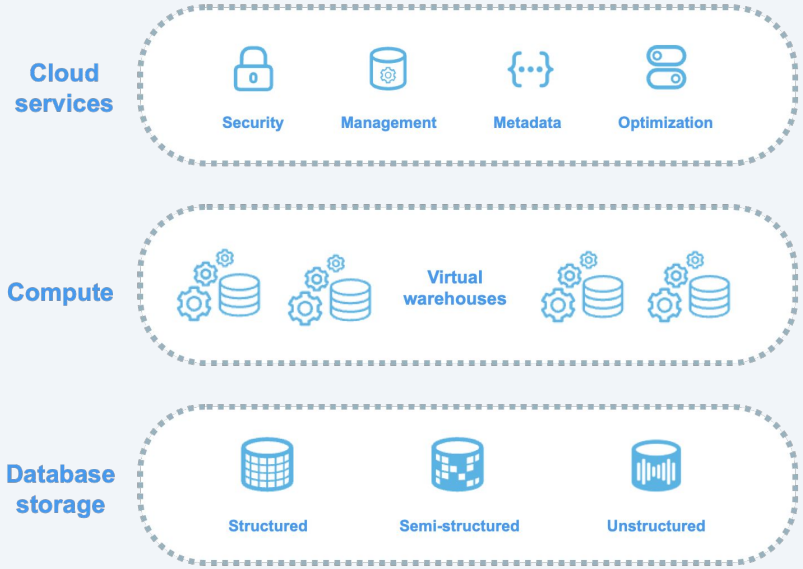
Nguồn: **ClickHouse Documentation — "Architecture overview" (VLDB 2024 paper web version)**
https://clickhouse.com/docs/concepts/core-concepts/academic-overview

Vì sao các nền tảng hiện đại làm ranh giới mờ đi?

SNOWFLAKE

- Centralized storage + Independent Virtual Warehouses + Cloud services layer
- Dynamic Tables theo Bronze / Silver / Gold
- Semantic Views khuyến nghị bắt đầu từ simple star schema

"Một storage core có thể phục vụ nhiều compute workload và nhiều kiểu data model cùng lúc."



Nguồn: **Snowflake Documentation — "Snowflake key concepts and architecture"**
https://docs.snowflake.com/en/user-guide/intro-key-concepts

CASE STUDY

SMART GREENHOUSE

Một bộ dữ liệu thực nghiệm, sáu câu hỏi vận hành.

WUR · Bleiswijk, Hà Lan | Cà chua bi Axiany | 12/2019–05/2020

https://www.kaggle.com/datasets/piantic/autonomous-greenhouse-challengeagc-2nd-2019/

TỪ DỮ LIỆU ĐẾN QUYẾT ĐỊNH



Ai dùng kết quả?

Người vận hành

Khí hậu, tưới — BR-01 · 02

Kỹ sư nông học

Dinh dưỡng, stress, rủi ro — BR-03 · 05 · 06

Quản lý trang trại

kWh/kg loại A, năng suất — BR-04 · 05

Sáu business requirement

Câu hỏi nghiệp vụ, bảng dữ liệu và kết quả cần trả lời

Mã	Tên	Câu hỏi	Bảng	Kết quả
BR-01	Tuân thủ khí hậu	Nằm ngoài dải nhiệt độ / CO_2 bao nhiêu giờ?	FactClimate	Giờ và % lệch setpoint, theo tuần
BR-02	Sử dụng nước	Tưới bao nhiêu L/m², rỉ bao nhiêu, mưa có đổi nhịp tưới?	FactIrrigation FactWeather	L/m² tưới và drain theo tuần; đối chiếu mưa với nhịp tưới
BR-03	Ổn định dinh dưỡng	EC hoặc pH dung dịch drain ngoài dải an toàn bao lâu?	FactRootzone	Giờ ngoài dải: EC [2–5 dS/m], pH [5,5–6,5]
BR-04	Cường độ năng lượng	Bao nhiêu kWh cho mỗi kg quả loại A?	FactEnergy FactHarvest	kWh/kg loại A theo khoang; xếp hạng 6 đội khi đủ dữ liệu
BR-05	Năng suất và khí hậu	Khoang năng suất cao có ít giờ stress hơn không?	FactHarvest FactClimate	kg/m² đối chiếu giờ stress; không kết luận nhân quả
BR-06	Giờ rủi ro bệnh	Bao nhiêu giờ trong vùng dễ phát nấm?	FactClimate	Giờ có RH ≥ 85% và 15°C ≤ Tair ≤ 25°C

Cả 6 BR trả lời bằng SQL, không kích hoạt thiết bị. Kết quả kèm coverage; BR-06 là proxy khí hậu, không phải giờ cây bị bệnh.

CASE STUDY — DATASET

Dữ liệu thật, nhiều grain: cần chuẩn hóa trước

43 CSV

và 2 PDF trong archive Kaggle

47.809

dòng climate mỗi khoang (5 phút)

166 ngày

dữ liệu tài nguyên mỗi khoang

Các nhóm dữ liệu & nhịp đo

Climate / Weather	5 phút
Resources (nước, điện, nhiệt)	theo ngày
Production	ngày thu hoạch
Lab / chất lượng quả	~2 tuần

Ba rủi ro cần giữ đúng nghĩa

- Đơn vị khác nhau: Heat_cons là MJ/m², ProdA là kg/m²
- AICU thiếu requested setpoint: ~70% t_heat_sp, 86% co2_sp
- Reference có ngày thu hoạch nằm ngoài vụ (14/02/2019) → cách ly bản ghi; KPI chưa đầy đủ

SCHEMA 1 — INMON (CORE 3NF)

Core 3NF: tích hợp theo thực thể nghiệp vụ

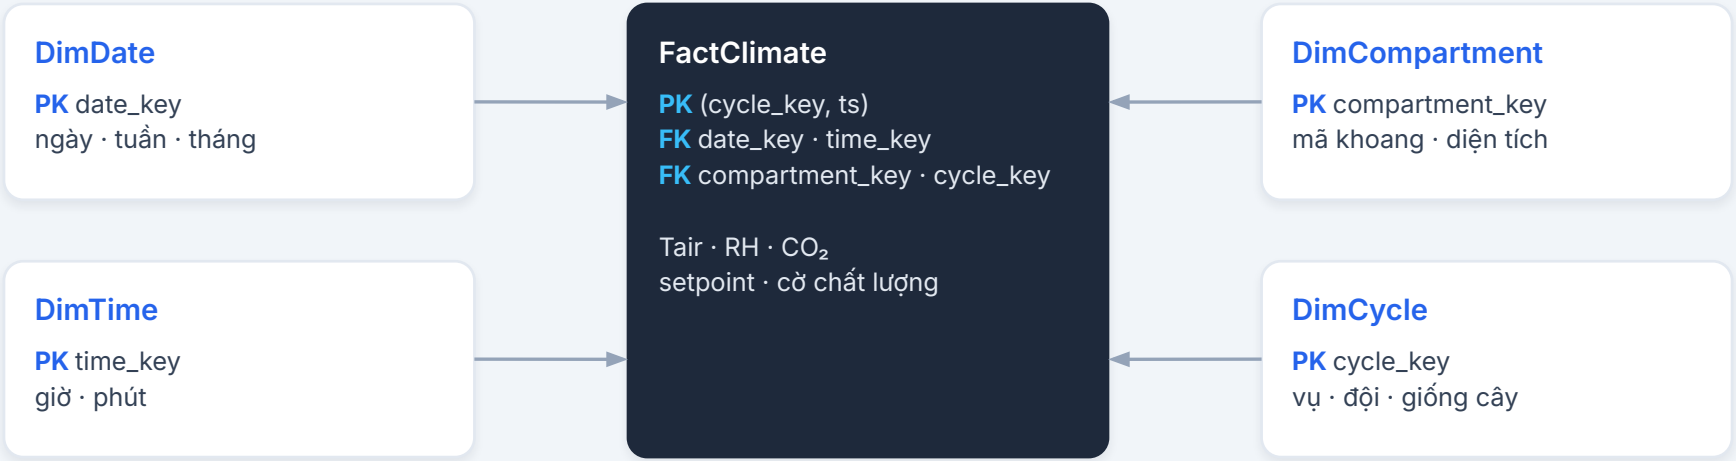


Một cycle = một vụ của một khoang. Typed-wide có thể đạt 3NF; không bắt buộc EAV.

Schema đề xuất, mẫu rút gọn (lược SITE, TEAM, CROP) · PK: khóa chính · FK: khóa ngoại

SCHEMA 2 — KIMBALL (STAR SCHEMA)

Star schema: tổ chức theo business process



Grain: cycle × 5 phút. Energy/Harvest: tổng hợp riêng cùng cycle và cửa sổ, rồi drill-across.

Schema đề xuất · mẫu FactClimate · mũi tên: dimension → fact (1 : N)

SCHEMA 3 — HYBRID (CORE → MARTS)

Core chuẩn hóa → marts dùng dimension chung

CORE 3NF

ResourceDay

PK (cycle_id, date)
heat_mj_m2 · điện · nước

Harvest

PK (cycle_id, harvest_date)
prod_a_kg_m2 · prod_b_kg_m2

MJ/m² ÷ 3,6 → kWh/m²

gán khóa dimension

DIMENSIONAL MARTS

FactEnergyDay

PK/FK (cycle_key, date_key)
heat_kwh_m2 · electricity_kwh_m2

FactHarvest

PK/FK (cycle_key, date_key)
prod_a_kg_m2 · prod_b_kg_m2

DimCycle + DimDate dùng chung cho cả hai fact

Raw giữ nguyên; mart chỉ lấy từ core. Core lo nghĩa dữ liệu, mart lo khai thác.

SO SÁNH

Tiêu chí	Inmon	Kimball	Hybrid
Trọng tâm	Tích hợp thực thể	Process + grain	Core + marts
Lớp BI	Có thể thêm mart	Star là trọng tâm	Star sinh từ core
Ra báo cáo đầu tiên	Xây nền trước	Từng process	Thêm một bước core
Chi phí quản trị	Mô hình tích hợp	Chiều dùng chung	Hai lớp + đối soát
Hợp case này khi	Ưu tiên core	Đủ và đơn giản hơn	Cần core + marts riêng

KẾT LUẬN

Chọn Hybrid, không xây quá phạm vi

1. **Chuẩn hóa có một nơi chịu trách nhiệm**

   Core dùng chung quản lý khóa, đơn vị, setpoint và chất lượng dữ liệu.

2. **Marts phục vụ đúng sáu BR**

   Khí hậu, nước, dinh dưỡng, năng lượng, năng suất, rủi ro nấm.

3. **Đối soát được core ↔ mart**

   Kiểm tra tổng, coverage; tái tính theo rule version.



ĐÁNH ĐỔI

Thêm pipeline, lưu trữ và kiểm thử cho hai lớp.

Kimball cũng xử lý được và đủ cho 6 BR; Hybrid tách riêng core để đối soát.

Q&A

CẢM ƠN!

Cảm ơn cô và các bạn đã lắng nghe!

